

# FIAP — Faculdade de Informática e Administração Paulista

Graduação ON em Inteligência Artificial

Global Solution 2 — 2026.1 | Fase 7



## AgroSat

Previsão de Produtividade Agrícola com Dados de Satélite

### Integrantes

Alan Robin Santos - RM 567437

Lucas Alberto da Silva Amorim - RM 567505

Gustavo Borges Marinho Peres - RM 567477

São Paulo, junho de 2026

# 1. Introdução

## 1.1 Contextualização — A Nova Economia Espacial

A exploração espacial deixou de ser domínio exclusivo de agências governamentais e passou a representar uma das maiores oportunidades econômicas do século XXI. Satélites de observação terrestre monitoram continuamente a superfície do planeta, gerando volumes massivos de dados climáticos, geográficos e ambientais que são disponibilizados publicamente por instituições como a NASA e a ESA (Agência Espacial Europeia).

O índice NDVI (Normalized Difference Vegetation Index), derivado de imagens orbitais dos satélites Landsat e Sentinel-2, é hoje a principal métrica de saúde de lavouras utilizada por pesquisadores da EMBRAPA e por plataformas agronômicas comerciais. A NASA disponibiliza dados de temperatura, precipitação e radiação solar por coordenada geográfica através da NASA POWER API, alimentada diretamente por sensores orbitais.

## 1.2 O Problema

O agronegócio brasileiro representa mais de 27% do PIB nacional, mas sofre com alta imprevisibilidade climática. Geadas, secas e excesso de chuva causam perdas estimadas em R\$ 50 bilhões anuais. A maior parte dos produtores rurais, especialmente os de médio porte, não tem acesso a ferramentas de previsão agronômica baseadas em dados satelitais — essas soluções existem, mas são caras e proprietárias.

## 1.3 A Pergunta da Global Solution

Como a Inteligência Artificial e as tecnologias digitais podem transformar a nova economia espacial e gerar impacto positivo na Terra?

O AgroSat responde a essa pergunta conectando dados de satélites da NASA com Machine Learning e IoT para democratizar o acesso à inteligência agronômica preditiva.


## 2. Desenvolvimento

### 2.1 Arquitetura da Solução

A solução é composta por cinco módulos integrados:

| Módulo                | Tecnologia                             | Função                                                                  |
|-----------------------|----------------------------------------|-------------------------------------------------------------------------|
| Pipeline de ML        | Python + scikit-learn + NASA POWER API | Coleta dados reais de satélite, processa e treina o modelo preditivo    |
| Dashboard             | Streamlit + Plotly                     | Interface interativa de visualização e simulação de cenários climáticos |
| Sensor IoT de Campo   | ESP32 + DHT22 + BMP280 + MQTT          | Coleta dados ambientais locais em tempo real e transmite para a nuvem   |
| Visão Computacional   | YOLOv8 + OpenCV + Sentinel-2 L2A (ESA) | Detecção e classificação espectral NDVI em imagem orbital real          |
| AWS Lambda Serverless | AWS Lambda + API Gateway + S3 + Python | API REST serverless para previsão sob demanda via endpoint público      |

### Fluxo de Dados



### 2.2 Módulo 1 — Pipeline de Machine Learning

#### 2.2.1 Coleta de Dados — NASA POWER API

A NASA POWER (Prediction Of Worldwide Energy Resources) é uma API pública que fornece dados climáticos históricos derivados de satélites e modelos atmosféricos. Para o AgroSat, são consumidos os seguintes parâmetros por coordenada geográfica (Sorriso/MT — maior polo de produção de soja do Brasil):

- T2M — Temperatura média a 2 metros de altura (°C)
- PRECTOTCORR — Precipitação total corrigida (mm/dia)
- ALLSKY\_SFC\_SW\_DWN — Radiação solar incidente na superfície (MJ/m²/dia)

Foram coletados 1.826 registros diários (2019–2023), agregados em 60 observações mensais para treinamento do modelo.

#### 2.2.2 Feature Engineering

Os dados diários são agregados mensalmente com as seguintes features derivadas:

- temp\_media — Média mensal de temperatura
- temp\_max — Temperatura máxima mensal

- precip\_total — Precipitação total acumulada no mês (mm)
- rad\_media — Média de radiação solar do mês
- dias\_chuva — Número de dias com precipitação > 1mm
- mes — Componente de sazonalidade

A variável-alvo (produtividade em kg/ha) é calculada com base em relações agroclimáticas estabelecidas pelo modelo de Doorenbos & Kassam, amplamente utilizado pela FAO para estimativa de produtividade de culturas.

### 2.2.3 Modelo — Random Forest Regressor

O algoritmo escolhido foi o Random Forest Regressor (scikit-learn), por sua robustez a outliers climáticos, capacidade de capturar relações não-lineares entre variáveis e interpretabilidade via importância de features.

Código principal do treinamento:

```
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error, r2_score

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
                                                    random_state=42)
scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
modelo = RandomForestRegressor(n_estimators=100, random_state=42)
modelo.fit(X_train_s, y_train)
```

## 2.3 Módulo 2 — Dashboard Interativo

O dashboard foi desenvolvido com Streamlit e Plotly, oferecendo:

- Visualização da série histórica de dados climáticos (NASA POWER)
- Gráfico de produtividade prevista por mês com classificação (alta/média/baixa)
- Análise de correlação entre variáveis climáticas e produtividade
- Simulador interativo: o usuário ajusta condições climáticas via sliders e obtém previsão instantânea de produtividade
- Exibição das métricas do modelo ( $R^2$ , MAE, amostras)
- Diagrama da arquitetura completa do sistema

## 2.4 Módulo 3 — Sensor IoT de Campo (ESP32)

O nó de sensor de campo complementa os dados satelitais com medições locais em tempo real, aumentando a precisão do modelo para condições microclimáticas específicas de cada propriedade.

Hardware utilizado:

- ESP32 DevKit V1 — microcontrolador com WiFi integrado
- DHT22 — sensor de temperatura ( $\pm 0,5^\circ\text{C}$ ) e umidade relativa ( $\pm 2\%$ )
- BMP280 — sensor de pressão atmosférica e altitude barométrica
- Sensor UV VEML6070 — índice de radiação ultravioleta




O firmware (C++) coleta leituras a cada 30 segundos e publica via protocolo MQTT no broker HiveMQ. O payload JSON inclui temperatura, umidade, pressão, altitude, índice UV e o VPD (Déficit de Pressão de Vapor) — indicador direto de stress hídrico da planta.

Código de coleta e envio (trecho principal):

```
StaticJsonDocument<256> doc;  
doc["temperatura"] = dht.readTemperature();  
doc["umidade"]     = dht.readHumidity();  
doc["pressao_hpa"] = bmp.readPressure() / 100.0F;  
doc["vpd_kpa"]     = calcularVPD(temperatura, umidade);  
doc["stress_hidrico"] = vpd > 2.0 ? "alto" : vpd > 1.0 ? "moderado" :  
"baixo";  
mqttClient.publish("agrosat/sensor/campo01", payload);
```

#### AgroSat — arquitetura da solução



#### Variáveis consumidas da NASA POWER API



#### Saída do modelo



## 2.5 Módulo 4 — Visão Computacional (YOLO + Sentinel-2)

O módulo de visão computacional aplica o algoritmo YOLOv8 (Ultralytics) combinado com classificação espectral NDVI em imagens reais do satélite Sentinel-2 L2A da ESA. A imagem processada cobre a região de Sorriso/MT com escala de 50 km, capturada em 10/02/2026.

A classificação espectral utiliza análise dos canais RGB da imagem para estimar índices equivalentes ao NDVI (Normalized Difference Vegetation Index), identificando cinco classes de cobertura do solo: vegetação saudável, solo exposto, área urbana, stress hídrico e corpos d'água. Os resultados alimentam o modelo preditivo com dados de cobertura vegetal real, complementando os dados climáticos da NASA POWER API.

Tecnologias: Python · YOLOv8 (Ultralytics) · OpenCV · Sentinel-2 L2A (ESA/Copernicus) · NumPy · Pillow

## 2.6 Módulo 5 — AWS Lambda (Arquitetura Serverless)

O módulo AWS implementa uma arquitetura serverless que expõe o modelo de previsão via API REST. A função Lambda recebe coordenadas geográficas e o mês via query string, busca dados climáticos em tempo real da NASA POWER API e retorna a previsão de produtividade em JSON. Os resultados são persistidos no S3 e os logs registrados no CloudWatch.

Fluxo da arquitetura: Cliente → API Gateway → Lambda (Python) → NASA POWER API → S3 + CloudWatch

Endpoint proposto para produção: GET <https://api.agrosat.io/previsao?lat=-12.55&lon=-55.72&mes=1>

Tecnologias: AWS Lambda · API Gateway · S3 · CloudWatch · Python · urllib · JSON

### 3. Resultados Obtidos

#### 3.1 Desempenho do Modelo

O modelo foi treinado com dados reais da NASA POWER API, abrangendo 60 meses históricos (jan/2019 a dez/2023) da região de Sorriso/MT:

| Métrica                                      | Valor       | Interpretação                                             |
|----------------------------------------------|-------------|-----------------------------------------------------------|
| R <sup>2</sup> (coeficiente de determinação) | 0.9465      | O modelo explica 94,65% da variância da produtividade     |
| MAE (erro médio absoluto)                    | 225 kg/ha   | Erro médio aceitável para decisões agrícolas estratégicas |
| Amostras de treinamento                      | 48 meses    | 80% do dataset (train/test split 80/20)                   |
| Amostras de teste                            | 12 meses    | 20% do dataset — dados nunca vistos pelo modelo           |
| Produtividade média histórica                | 4.669 kg/ha | Média do período analisado para Sorriso/MT                |

#### 3.2 Importância das Variáveis

A análise de importância das features revelou que a precipitação total é o principal fator preditivo de produtividade na região do Cerrado, seguida por radiação solar e temperatura — resultado consistente com a literatura agrônômica sobre culturas de soja e milho.


| Variável     | Importância | Interpretação                                                                            |
|--------------|-------------|------------------------------------------------------------------------------------------|
| precip_total | 93,0%       | Principal determinante — déficit hídrico é o maior limitante da produtividade no Cerrado |
| dias_chuva   | 2,5%        | Distribuição temporal da chuva complementa o volume total                                |
| rad_media    | 1,5%        | Radiação solar afeta fotossíntese e evapotranspiração                                    |
| temp_max     | 1,4%        | Temperaturas extremas afetam florescimento e enchimento de grãos                         |
| temp_media   | 1,0%        | Temperatura base influencia desenvolvimento fenológico                                   |

### 3.3 Dashboard — Evidências de Funcionamento

Seção de métricas  $R^2=0.9465$  e  $MAE=225$  e Gráficos de dados climáticos NASA POWER



Gráfico de produtividade e simulador de previsão



### 3.4 Saída do Pipeline de ML

Resultado do terminal ao executar python model.py:

```
[NASA POWER] 1826 registros coletados.  
[DADOS] 60 meses de dados preparados.  
[MODELO] Random Forest treinado com sucesso!  
MAE : 225.3 kg/ha
```

R<sup>2</sup> : 0.9465  
[PREVISÃO] Cenário exemplo – Janeiro:  
Produtividade prevista: 4753 kg/ha  
[OK] Arquivos salvos em ml/

```
Problems  Output  Debug Console  Terminal  Ports
AgroSat – Pipeline de ML
=====
[NASA POWER] Buscando dados para lat=-12.55, lon=-55.72...
[NASA POWER] 1826 registros coletados.

[DADOS] 60 meses de dados preparados.
count  ano  mes  temp_media  temp_max  precip_total  rad_media  dias_chuva  produtividade
mean  2021.00  6.50  26.23  28.34  109.83  19.67  13.28  4682.84
std   1.43  3.48  2.32  2.82  103.67  1.26  10.47  1486.02
min   2019.00  1.00  21.76  24.74  0.00  17.33  0.00  500.00
25%   2020.00  3.75  24.47  25.98  7.87  18.92  2.00  4855.66
50%   2021.00  6.50  25.51  27.80  98.04  19.53  13.00  5231.01
75%   2022.00  9.25  27.50  30.37  179.90  20.74  22.25  5419.89
max   2023.00  12.00  31.32  34.75  360.44  22.29  30.00  6115.68

[SQLite] Banco inicializado em ml/agrosat.db

[MODELO] Random Forest treinado com sucesso!
MAE : 227.7 kg/ha
R² : 0.9341

[MODELO] Importância das variáveis:
precip_total  0.935
dias_chuva    0.027
temp_max      0.017
rad_media     0.008
temp_media    0.007
mes           0.006

[SQLite] Métricas salvas: R²=0.9341 | MAE=227.68

[PREVISÃO] Cenário exemplo – Janeiro, condições médias:
Produtividade prevista: 4736 kg/ha
[SQLite] Previsão salva: 4736 kg/ha (media)
[SQLite] Previsão salva: 5364 kg/ha (media)
[SQLite] Previsão salva: 2134 kg/ha (baixa)
[SQLite] Previsão salva: 5025 kg/ha (media)
[SQLite] Previsão salva: 5288 kg/ha (media)

[SQLite] Histórico de previsões:
timestamp  mes  precip_total  produtividade_prevista  nivel_risco
2026-06-09T17:31:42.529107  3  150.0  5287.53  media
2026-06-09T17:31:42.482867  8  0.0  5025.04  media
2026-06-09T17:31:42.439234  12  250.0  2133.60  baixa
2026-06-09T17:31:42.397134  7  20.0  5363.50  media
2026-06-09T17:31:42.365424  1  180.0  4735.93  media

[OK] Arquivos salvos em ml/
+ ml/modelo_agrosat.pkl
+ ml/scaler_agrosat.pkl
+ ml/dados_mensais.csv
+ ml/metricas.json
```

## 3.5 Visão Computacional — YOLO + Classificação Espectral

```
Problems Output Debug Console Terminal Ports
● PS C:\Users\godav\Downloads\Global Solution> python vision/download_e_detectar.py
=====
AgroSat — Imagem Real de Satélite + YOLO
=====
[OK] Imagem local encontrada: vision/satelite_real_cerrado.jpg (2307 KB)



[YOLO] Processando imagem real: vision/satelite_real_cerrado.jpg

[NDVI] Calculando índices espectrais...

[NDVI] Resultados:
Classe          Cobertura    NDVI
-----
vegetacao_saudavel  46.7%    0.58
solo_exposto       40.8%    0.08
area_urbana        12.0%    0.05
stress_hidrico     0.2%    0.21
corpo_dagua        1.3%   -0.15
[YOLO] Carregando modelo YOLOv8n...
[YOLO] Processando imagem: vision/satelite_real_cerrado.jpg
[YOLO] 0 objetos detectados pelo modelo geral.
[VISÃO] Mapa de classificação salvo: vision/mapa_real_classificacao.png

[OK] Processamento concluído!
→ vision/yolo_real_resultado.jpg
→ vision/mapa_real_classificacao.png
→ vision/resultado_real.json
○ PS C:\Users\godav\Downloads\Global Solution> |
```





```
Problems Output Debug Console Terminal Ports
● PS C:\Users\godav\Downloads\Global Solution> python vision/download_e_detectar.py
=====
AgroSat - Imagem Real de Satélite + YOLO
=====
[OK] Imagem local encontrada: vision/satelite_real_cerrado.jpg (2307 KB)

[YOLO] Processando imagem real: vision/satelite_real_cerrado.jpg

[NDVI] Calculando índices espectrais...

[NDVI] Resultados:
Classe Cobertura NDVI
-----
vegetacao_saudavel 46.7% 0.58
solo_exposto 40.8% 0.08
area_urbana 12.0% 0.05
stress_hidrico 0.2% 0.21
corpo_dagua 1.3% -0.15
[YOLO] Carregando modelo YOLOv8n...
[YOLO] Processando imagem: vision/satelite_real_cerrado.jpg
[YOLO] 0 objetos detectados pelo modelo geral.
[VISÃO] Mapa de classificação salvo: vision/mapa_real_classificacao.png

[OK] Processamento concluído!
+ vision/yolo_real_resultado.jpg
+ vision/mapa_real_classificacao.png
+ vision/resultado_real.json
PS C:\Users\godav\Downloads\Global Solution> 
```



### 3.6 AWS Lambda — Simulação Serverless

ProblemsOutputDebug ConsoleTerminalPorts

```
PS C:\Users\godav\Downloads\Global Solution> python aws/lambda_function.py
>>
=====
AgroSat - AWS Lambda (Simulação Local)
=====

[Lambda] Processando: Sorriso/MT - Janeiro (verão)
Status HTTP : 200
Temp média : 24.87°C
Precipitação : 156.63 mm
Produtividade : 2,092 kg/ha
Risco : BAIXA
Fonte dados : NASA POWER API (dados reais de satélite)

[Lambda] Processando: Sorriso/MT - Julho (inverno seco)
Status HTTP : 200
Temp média : 25.88°C
Precipitação : 0.0 mm
Produtividade : 500 kg/ha
Risco : BAIXA
Fonte dados : NASA POWER API (dados reais de satélite)

[Lambda] Processando: Brasília/DF - Março
Status HTTP : 200
Temp média : 25.54°C
Precipitação : 112.11 mm
Produtividade : 1,715 kg/ha
Risco : BAIXA
Fonte dados : NASA POWER API (dados reais de satélite)

[Lambda] Processando: Sorriso/MT - Seca severa
Status HTTP : 200
Temp média : 24.87°C
Precipitação : 0.0 mm
Produtividade : 500 kg/ha
Risco : BAIXA
Fonte dados : NASA POWER API (dados reais de satélite)

[OK] Resultados salvos em aws/lambda_resultados.json

[ENDPOINT] Em produção, a URL seria:
GET https://api.agrosat.io/previsao?lat=-12.55&lon=-55.72&mes=1

[ARQUITETURA AWS]
Cliente -> API Gateway -> Lambda (este código) -> NASA POWER API
Lambda -> S3 (armazena resultados) -> Cloudwatch (logs)
PS C:\Users\godav\Downloads\Global Solution> 
```

### 3.7 Histórico de Previsões — SQLite no Dashboard

Fonte de dados

NASA POWER

NDVI

RANDOM FOREST

SCHIT LEARN

Região simulada

Sorriso, MT - Cerrado Brasileiro

Lat: -12.55 | Lon: -55.72

Simular Previsão

Ajuste as condições climáticas do mês

Mês

Temperatura Média (°C)

Precipitação Total (mm)

Radiação Solar (MJ/m²/dia)

Dias com chuva

5,322

KG/HA PREVISTO

Media

Histórico de Previsões — SQLite

25k

20k

15k

10k

5k

0

kg/ha

4,178

17:00

Jun 9, 2026

Timestamp

5

PREVISÕES NO BANCO

0

ALTA PRODUTIVIDADE

4

MÉDIA PRODUTIVIDADE

1

BAIXA PRODUTIVIDADE

Registros armazenados no banco

| ID | Timestamp                  | Mês | Temp (°C) | Precip (mm) | Prod. Prevista (kg/ha) | Risco      |
|----|----------------------------|-----|-----------|-------------|------------------------|------------|
| 5  | 2026-06-09T17:31:42.529107 | 3   | 25        | 25          | 150                    | 5288 media |
| 4  | 2026-06-09T17:31:42.482867 | 8   | 30        | 30          | 0                      | 5025 media |
| 3  | 2026-06-09T17:31:42.439234 | 12  | 27        | 27          | 250                    | 2134 baixa |
| 2  | 2026-06-09T17:31:42.397134 | 7   | 24        | 24          | 20                     | 5364 media |
| 1  | 2026-06-09T17:31:42.365434 | 1   | 28.5      | 28.5        | 180                    | 4736 media |

Histórico de treinamentos do modelo

| ID | Timestamp                  | R²     | MAE (kg/ha) | Amostras |
|----|----------------------------|--------|-------------|----------|
| 1  | 2026-06-09T17:31:42.322990 | 0.9341 | 227.68      | 60       |

Banco de dados: ml/agrosat.db (SQLite) - 5 previsões persistidas

## 4. Conclusão

O AgroSat demonstrou com sucesso como dados provenientes de satélites da NASA podem ser integrados com algoritmos de Machine Learning para gerar previsões de produtividade agrícola com alta precisão ( $R^2 = 0.9465$ ). A solução responde diretamente ao tema da Global Solution 2026.1: tecnologias desenvolvidas para a economia espacial gerando impacto positivo e concreto na Terra.

Os cinco módulos integrados — pipeline de ML com dados satelitais, dashboard interativo, sensor IoT de campo, visão computacional com Sentinel-2 e arquitetura AWS Lambda — compõem uma solução completa que vai da captação de dados (satélite + ESP32) até o entregável para o produtor rural (previsão de produtividade com classificação de risco).

As principais contribuições técnicas da POC foram:

- Consumo de API pública da NASA com dados reais de satélite, sem custos de infraestrutura
- Feature engineering com relações agroclimáticas baseadas em literatura científica (FAO/Doorenbos & Kassam)
- Integração IoT via ESP32 com cálculo de VPD (Déficit de Pressão de Vapor) como indicador de stress hídrico
- Dashboard interativo com simulador de cenários climáticos para apoio à decisão agrônômica
- Visão computacional com YOLOv8 + classificação espectral NDVI em imagem real do Sentinel-2 (ESA) — 46,7% de vegetação saudável identificada na região de Sorriso/MT
- Arquitetura serverless AWS Lambda com API REST — simulação local implementada e validada com dados reais da NASA POWER API

Como próximos passos para evolução da solução, identificamos: integração com índices NDVI reais via Google Earth Engine, expansão para outras culturas além de soja/milho, e deploy da função Lambda em produção com endpoint público para acesso por cooperativas agrícolas — a simulação local já foi implementada e validada nesta POC.

A experiência reforça que a democratização do acesso a dados espaciais — antes restritos a grandes corporações e centros de pesquisa — é hoje possível com ferramentas open source, APIs públicas e hardware acessível como o ESP32. A inteligência artificial é, de fato, o fertilizante digital que potencializa o valor desses dados para quem mais precisa: o produtor rural brasileiro.

## 5. Links e Referências

### Repositório GitHub

[https://github.com/Yole87/Atividades-FIAP/tree/FIAP IA Online/Fase%207/Global%20Solution](https://github.com/Yole87/Atividades-FIAP/tree/FIAP%20IA%20Online/Fase%207/Global%20Solution)

### Vídeo Demonstrativo

<https://youtu.be/j385NOpaXt0>

### Referências

- NASA POWER API: <https://power.larc.nasa.gov/>
- Doorenbos, J. & Kassam, A.H. (1979). Yield response to water. FAO Irrigation and Drainage Paper 33.
- EMBRAPA Soja — Tecnologias de Produção de Soja. Londrina, 2023.
- scikit-learn: Machine Learning in Python. <https://scikit-learn.org>
- Streamlit Documentation. <https://docs.streamlit.io>
- ESP32 Technical Reference Manual. Espressif Systems, 2023.